

Actividad 1.5 Combinaciones lineales y Validación de la Normal Multivariada

Franco Mendoza Muraira A01383399

2023-11-10

1. Matriz X

```
X = matrix(c(1,4,3,6,2,6,8,3,3),nrow=3,ncol=3,byrow=TRUE)
X
```

```
##      [,1] [,2] [,3]
## [1,]    1    4    3
## [2,]    6    2    6
## [3,]    8    3    3
```

$$b'X = X_1 + X_2 + X_3$$

$$c'X = X_1 + 2X_2 - 3X_3$$

a) Hallar la media, varianza y covarianza de X

```
## Media de X: 5 3 4
```

```
##
```

```
##
```

```
## Varianza de X:
```

```
##      [,1] [,2] [,3]
## [1,] 13.0 -2.5  1.5
## [2,] -2.5  1.0 -1.5
## [3,]  1.5 -1.5  3.0
```

```
##
```

```
##
```

```
## Covarianza de X:
```

```
##      [,1] [,2] [,3]
## [1,] 13.0 -2.5  1.5
## [2,] -2.5  1.0 -1.5
## [3,]  1.5 -1.5  3.0
```

b) Hallar la media, varianza y covarianza de $b'X$ y $c'X$

Media

```
bc = matrix(c(1,1,1,1,2,-3),nrow=2,ncol=3,byrow=TRUE)
mediabc = bc%%mediaX
mediabc
```

```
##      [,1]
## [1,]   12
## [2,]   -1
```

Matriz de Varianzas y covarianzas

```
varianzabc = bc%%varianzaX%%t(bc)
varianzabc
```

```
##      [,1] [,2]
## [1,]   12  -3
## [2,]   -3  43
```

c) Hallar el determinante de S

```
## c) Determinante de S (matriz de var-covarianzas de X):  0
```

d) Hallar los valores y vectores propios de S

```
## d) Valores propios de S:
##  13.7915  3.208497 -7.859007e-17
```

```
##
##
```

```
## d) Vectores propios de S:
```

```
##      [,1]      [,2]      [,3]
## [1,]  0.9645458 -0.2295697 -0.1301889
## [2,] -0.2076189 -0.3555080 -0.9113224
## [3,]  0.1629288  0.9060418 -0.3905667
```

e) Argumentar si hay independencia entre $b'X$ y $c'X$, ¿y qué ocurre con X_1 , X_2 y X_3 ? ¿son independientes?

```
bx = matrix(c(1,1,1),nrow=1,ncol=3)
cx=matrix(c(1,2,-3),nrow=1,ncol=3)
cor.test(X[,1],X[,2])
```

```
##
## Pearson's product-moment correlation
##
## data: X[, 1] and X[, 2]
## t = -0.96225, df = 1, p-value = 0.5122
## alternative hypothesis: true correlation is not equal to 0
## sample estimates:
##      cor
## -0.6933752
```

```
cor.test(X[,1],X[,3])
```

```
##
## Pearson's product-moment correlation
##
## data: X[, 1] and X[, 3]
## t = 0.24744, df = 1, p-value = 0.8456
## alternative hypothesis: true correlation is not equal to 0
## sample estimates:
##      cor
## 0.2401922
```

```
cor.test(X[,2],X[,3])
```

```
##
## Pearson's product-moment correlation
##
## data: X[, 2] and X[, 3]
## t = -1.7321, df = 1, p-value = 0.3333
## alternative hypothesis: true correlation is not equal to 0
## sample estimates:
##      cor
## -0.8660254
```

H_0 : Correlación = 0

H_1 : Correlación \neq 0

Debido a que los p valores de todas las combinaciones de columnas en la matriz X son mayor a el nivel de significancia de 0.05, no podemos rechazar la hipótesis nula, por lo que se concluye que la correlación entre las variables es = 0. Como la matriz original es independiente, se sabe que todas las combinaciones serán independientes.

Hallar la varianza generalizada de S. Explicar el comportamiento de los datos de X basándose en los la varianza generalizada, en los valores y vectores propios de S.


La varianza generalizada de S es: 17

2. Explore los resultados del siguiente código y dé una interpretación.

```
library(MVN)

## Warning: package 'MVN' was built under R version 4.2.3


x = rnorm(100, 10, 2)
y = rnorm(100, 10, 2)
datos = data.frame(x,y)
mvn(datos, mvnTest = "hz", multivariatePlot = "persp")
```



```
## $multivariateNormality
##           Test      HZ  p value MVN
## 1 Henze-Zirkler 0.572713 0.442751 YES
##
## $univariateNormality
##           Test Variable Statistic  p value Normality
## 1 Anderson-Darling      x      0.4542    0.2645     YES
## 2 Anderson-Darling      y      0.4675    0.2455     YES
##
## $Descriptives
##      n      Mean Std.Dev  Median    Min     Max   25th   75th     Skew
```

```
## x 100 10.13709 1.794613 10.16735 4.006121 14.91636 9.263648 11.29666 -0.2891665
## y 100 10.00203 2.140028 9.80975 5.633720 15.48489 8.381147 11.37678 0.2730528
##      Kurtosis
## x 0.9095614
## y -0.6286527
```

```
mvn(datos, mvnTest = "hz", multivariatePlot = "contour")
```



```
## $multivariateNormality
##      Test      HZ  p value MVN
## 1 Henze-Zirkler 0.572713 0.442751 YES
##
## $univariateNormality
##      Test Variable Statistic  p value Normality
## 1 Anderson-Darling    x      0.4542    0.2645    YES
## 2 Anderson-Darling    y      0.4675    0.2455    YES
##
## $Descriptives
##      n      Mean Std.Dev  Median    Min     Max   25th   75th     Skew
## x 100 10.13709 1.794613 10.16735 4.006121 14.91636 9.263648 11.29666 -0.2891665
## y 100 10.00203 2.140028 9.80975 5.633720 15.48489 8.381147 11.37678 0.2730528
##      Kurtosis
## x 0.9095614
## y -0.6286527
```

Henze-Zirkler

H_0 : Los datos siguen una distribución normal multivariada.

H_1 : Los datos no siguen una distribución normal multivariada.

Debido a el alto valor p de los tests de Henze Zirkler, con un valor de 0.6316, no podemos rechazar la hipótesis nula, y se concluye qye los datos usados tienen una distribución normal multivariada.

Anderson-Darling

H_0 : Los datos siguen una distribución normal univariada.

H_1 : Los datos no siguen una distribución normal univariada.


Viendo que los pvalue de la prueba de Anderson-Darling es de 0.5405 en la primer variable, y 0.9752 en la segunda variable, y siendo que son mayores que el α de 0.05, no podemos rechazar la hipótesis nula, y se concluye que se presenta una distribución normal univariada en las 2 variables de los datos.

3. Un periódico matutino enumera los siguientes precios de autos usados para un compacto extranjero con edad medida en años y precio en venta medido en miles de dólares.

a) Diagrama de dispersión

```
x1 =c(1, 2, 3, 3, 4, 5, 6, 8, 9, 11)
x2=c(18.95, 19.00, 17.95, 15.54, 14.00, 12.95, 8.94, 7.49, 6.00, 3.99)
plot(x1,x2,col="purple",main="Diagrama de dispersión x1 y x2",xlab = "Edad (años)",ylab = "Precio en ve
```

Diagrama de dispersión x1 y x2



b) Inferir el signo de la covarianza a partir del gráfico

Viendo la gráfica se puede inferir que el signo de la covarianza muestral es negativo, esto porque las variables son inversamente proporcional entre ellas.

c) Calcular el cuadrado de las distancias de Mahalanobis

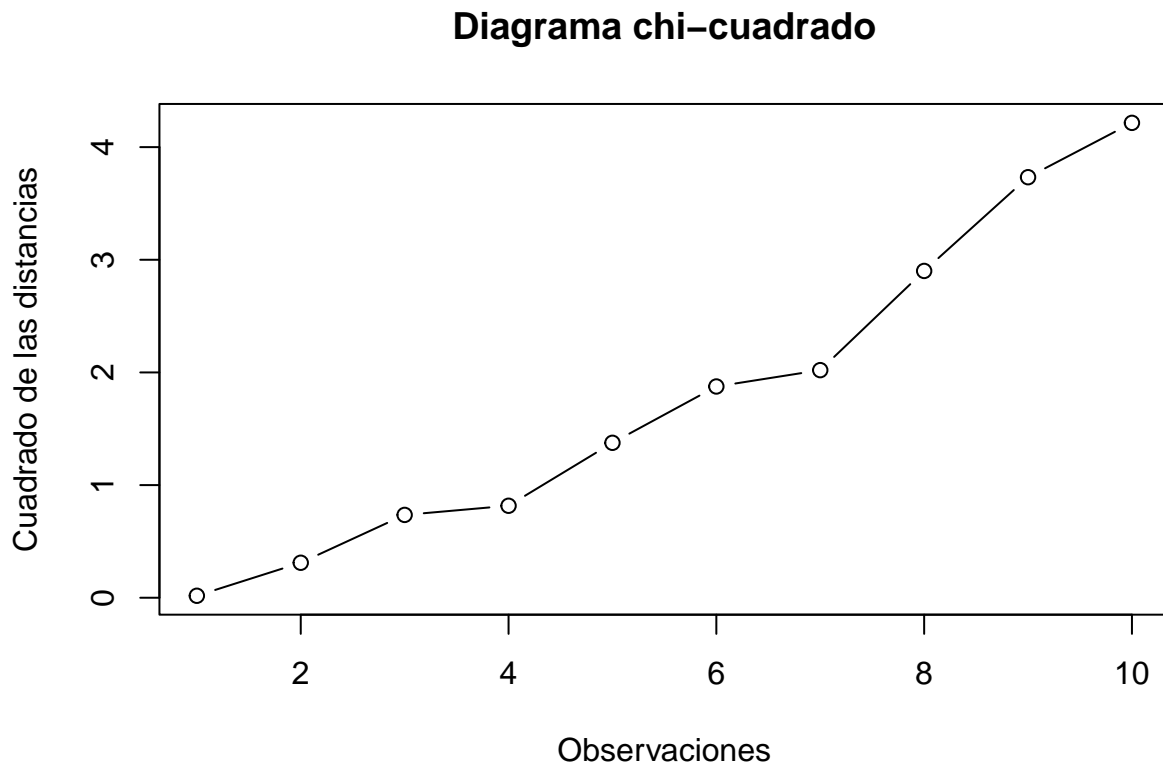
```
mx = cbind(x1,x2)
meanx = colMeans(mx)
varx=var(mx)
M = mahalanobis(mx,meanx,varx)
M
```

```
## [1] 1.8753045 2.0203262 2.9009088 0.7352659 0.3105192 0.0176162 3.7329012
## [8] 0.8165401 1.3753379 4.2152799
```

d) Usando las anteriores distancias, determine la proporción de las observaciones que caen dentro del contorno de probabilidad estimado del 50% de una distribución normal bivariada.

```
## Proporción de datos: 0.5
```

e) Ordene el cuadrado de las distancias del inciso c y construya un diagrama chi-cuadrado



f) Dados los resultados anteriores, serían argumentos para decir que son aproximadamente normales bivariadas?

Sí, acorde a como se distribuyen los datos, y como se ve la recta se puede creer que son aproximadamente normales bivariadas, aunque no siempre es seguro. Para asegurar esto, se tiene que hacer una prueba de shapiro:

```
shapiro.test(mx)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data:  mx  
## W = 0.92094, p-value = 0.1033
```

```
shapiro.test(M)
```

```
##  
## Shapiro-Wilk normality test  
##
```



```
## data:  M
## W = 0.93759, p-value = 0.5265
```

H_0 : Los datos siguen una distribución normal.

H_1 : Los datos no siguen una distribución normal.

Con como se ven estas pruebas, y debido a que ambas pruebas nos dan valores de p mayores que 0.05, no se tiene suficiente evidencia para rechazar la hipótesis nula, y se concluye que los datos se distribuyen de forma normal, al igual que las distancias cuadradas.